

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS SOCIALES



Pronóstico de percentiles extremos del tipo de cambio peruano

Metodología, especificación y resultados exploratorios de QBART

Comparación sistemática con Quantile Random Forest y Random Walk

Autora: Sinthya Bernabe Ortega
Código: 20222834
Profesor: Jairo Flores
Versión: Informe exploratorio v2
Fecha: 17 de julio de 2026

Lima, Perú

Resumen

Este informe documenta de manera reproducible la evaluación exploratoria de Bayesian Quantile Additive Regression Trees (QBART) para pronosticar los percentiles 5, 50 y 95 del retorno diario futuro del tipo de cambio nominal sol/dólar. El experimento emplea 6832 observaciones entre marzo de 2000 y junio de 2026, 46 predictores causales y una evaluación cronológica con ventana móvil de 2520 observaciones. QBART se estima con el kernel C++ oficial de BayesQArt y se compara, bajo la misma información y los mismos orígenes, con Quantile Random Forest (QRF), regresión cuantílica lineal y un benchmark de Random Walk definido mediante cuantiles históricos.

La calibración causal corrige la marcada contracción de las colas del QBART crudo: la cobertura pasa de 0,162 a 0,045 para el percentil 5 y de 0,844 a 0,950 para el percentil 95. Sin embargo, QRF mantiene una menor pérdida pinball en los tres percentiles. Frente a QRF, el QBART calibrado presenta pérdidas 21,4 %, 18,3 % y 16,9 % mayores para los percentiles 5, 50 y 95, respectivamente. Los tests de Diebold–Mariano rechazan igualdad predictiva a favor de QRF. Además, aunque QBART supera el test de cobertura incondicional de Kupiec luego de calibrarse, falla el test de cobertura dinámica en ambas colas. El análisis temporal muestra una señal favorable en 2026, pero insuficiente para revertir el resultado agregado.

En cuanto a los determinantes, la cola izquierda se asocia principalmente con medidas de volatilidad y forma de la distribución reciente, mientras que la cola derecha asigna mayor frecuencia a monedas internacionales, reservas, DXY y aceleración de volatilidad. Estas frecuencias son señales exploratorias de nacimientos de ramas aceptados, incluyendo burn-in, y no deben interpretarse como probabilidades posteriores de inclusión.

Palabras clave: tipo de cambio, riesgo de cola, regresión cuantílica, BART, QBART, Quantile Random Forest, pronóstico.

Clasificación JEL: C11, C14, C22, C53, F31, G17.

Índice

1. Objetivo y preguntas del ejercicio	1
1.1. Criterio de comparación	1
2. Diseño empírico	1
2.1. Variable objetivo	1
2.2. Muestra y partición cronológica	2
2.3. Ventana móvil y bloques de reestimación	2
2.4. Predictores	2
2.5. Prevención de look-ahead	3
3. Modelos	3
3.1. Random Walk cuantílico	3
3.2. Regresión cuantílica lineal	4
3.3. Quantile Random Forest	4
3.4. Bayesian Quantile Additive Regression Trees	4
4. Tuning y especificación seleccionada	6
4.1. Tuning por percentil	6
4.2. Tuning de QRF	6
5. Calibración causal de QBART	7
5.1. Motivación	7
6. Métricas y pruebas	8
6.1. Pérdida pinball	8
6.2. Cobertura	9
6.3. Kupiec, DQ y Diebold–Mariano	9
7. Ejercicios de validación previos	9
7.1. Revisión del sampler	9
7.2. Simulation gate	9
7.3. Pruebas de software	10
8. Resultados fuera de muestra	11
8.1. Pérdida pinball	11
8.2. Cobertura	12
8.3. Backtests corregidos	13
8.4. Comparación con la versión anterior	13
9. Estabilidad temporal	13
9.1. Resultados anuales	14
9.2. Resultados por bloque	15

10.Determinantes por percentil	15
10.1. Definición de la medida	15
10.2. Ranking principal	16
10.3. Interpretación de la cola izquierda	18
10.4. Interpretación del centro	19
10.5. Interpretación de la cola derecha	19
10.6. Asimetrías relevantes	19
11.Ejercicios adicionales de análisis	20
11.1. Ensamble diagnóstico QBART–QRF	20
11.2. Concentración de señales	20
11.3. Evaluación de régimen	20
12.Limitaciones	20
13.Agenda para mejorar QBART	21
13.1. Prioridad 1: calibración dinámica	21
13.2. Prioridad 2: mejorar la distribución de error	21
13.3. Prioridad 3: sparsity y selección de variables	22
13.4. Prioridad 4: inferencia posterior e importancia robusta	22
13.5. Prioridad 5: ventanas y regímenes	22
13.6. Prioridad 6: eficiencia computacional	22
13.7. Criterio para autorizar la corrida completa	23
14.Conclusiones	23
A. Reproducibilidad	23
A.1. Archivos principales	23
A.2. Comandos	24
B. Lista completa de predictores	24

1. Objetivo y preguntas del ejercicio

El objetivo es evaluar si una especificación bayesiana no paramétrica orientada directamente a cuantiles puede pronosticar la variabilidad extrema del tipo de cambio peruano y revelar determinantes diferentes en el centro y en las colas de la distribución condicional. El análisis se concentra en tres objetos:

1. el percentil 5 del retorno futuro, asociado a movimientos extremos negativos del tipo de cambio expresado en soles por dólar;
2. la mediana condicional, que sirve como referencia central; y
3. el percentil 95, asociado a movimientos extremos positivos y, bajo esta convención, a depreciaciones fuertes del sol.

La pregunta predictiva central es si QBART puede igualar o superar a QRFy al Random Walk en pérdida pinball fuera de muestra. La pregunta económica es si el conjunto de variables utilizado por los árboles cambia entre $\tau = 0.05, 0.50$ y 0.95 . Finalmente, se analiza si una buena cobertura incondicional implica también estabilidad temporal de las violaciones de los cuantiles.

1.1. Criterio de comparación

La comparación principal se realiza mediante pérdida pinball. Una menor pérdida representa un mejor pronóstico. La cobertura es una condición adicional: un percentil puede presentar cobertura cercana al valor nominal y, aun así, ser poco informativo o demasiado ancho. Por ello, cobertura y pinball se interpretan conjuntamente. QRF constituye el benchmark de aprendizaje automático más exigente; el Random Walk sirve como referencia parsimoniosa y la regresión cuantílica permite medir cuánto aporta la no linealidad.

2. Diseño empírico

2.1. Variable objetivo

Sea s_t el tipo de cambio nominal expresado en soles por dólar. El retorno diario se expresa en puntos porcentuales. Para horizonte $h = 1$, la variable objetivo disponible en la observación fechada en t es:

$$y_{t+1} = 100 \Delta \log(s_{t+1}). \quad (1)$$

En el código, el retorno futuro se construye desplazando la respuesta una observación hacia adelante. Los predictores de la fila t utilizan únicamente información observada hasta t . Una realización positiva corresponde a un aumento del precio del dólar y, por tanto, a una depreciación del sol.

2.2. Muestra y partición cronológica

Después de construir rezagos, transformaciones y estadísticas móviles, la muestra contiene 6 832 observaciones completas. No se realiza una división aleatoria. El primer 60 % se reserva como bloque inicial de entrenamiento, el siguiente 20 % como validación y el último 20 % como test.

Cuadro 1: Partición cronológica de la muestra

Bloque	Observaciones	Inicio	Fin
Muestra completa	6 832	27/03/2000	02/06/2026
Train inicial	4 099	27/03/2000	10/12/2015
Validación	1 366	11/12/2015	05/03/2021
Test	1 367	08/03/2021	02/06/2026

La estimación efectiva utiliza una ventana móvil de las últimas 2 520 observaciones disponibles. En el tuning se toman las últimas 2 520 observaciones del bloque inicial de entrenamiento.

2.3. Ventana móvil y bloques de reestimación

En cada origen de reestimación b , los modelos emplean:

$$\mathcal{I}_b = \{t_b - 2520, \dots, t_b - 1\}, \quad (2)$$

donde t_b es la primera fecha del bloque. El test se divide en 23 bloques de hasta 60 observaciones. Los modelos se reestiman al inicio de cada bloque y producen los cuantiles para las observaciones del bloque. Este esquema reduce el costo computacional, mantiene la dirección temporal y aplica el mismo conjunto de información a todos los métodos.

El diseño no equivale a una reestimación diaria. Dentro de cada bloque, los parámetros permanecen fijos hasta el siguiente origen. Esta aproximación es común a QBART, QRFy regresión cuantílica, por lo que conserva la equidad comparativa, pero puede reducir la capacidad de adaptación ante quiebres que ocurran dentro de los 60 días.

2.4. Predictores

El conjunto final contiene 46 variables. La Tabla 2 resume su construcción.

Cuadro 2: Grupos de predictores

Grupo	Número	Variables y transformación
Condiciones globales y tasas	9	VIX, BAA–Treasury spread, tasa de Estados Unidos, NFCL, yield to worst, term premia a 1, 5 y 10 años, y EMBIG Perú.
Política y mercado cambiario	4	Variación del VIX, diferencial de tasas Perú–Estados Unidos, intervención del BCRP e indicador de intervención faltante.
Precios y monedas	18	Cambios logarítmicos de reservas, oro, cobre, zinc, plata, S&P 500, MSCI emergentes, DXY y monedas internacionales y regionales. WTI usa diferencias de asinh porque puede tomar valores no positivos.
Dinámica del retorno	7	Cinco rezagos, valor absoluto y cuadrado del retorno más reciente.
Volatilidad y forma	8	Desviaciones estándar de 5, 20 y 60 días, EWMA con $\lambda = 0.94$, media absoluta de 20 días, asimetría de 20 días, curtosis de 60 días y ratio de volatilidad 5/60.
Total	46	

Las variables móviles incluyen la observación t , que está disponible al pronosticar $t + 1$. Los valores faltantes de intervención se sustituyen por cero, pero se incorpora un indicador de ausencia para distinguir “sin intervención” de “dato no reportado”. Las transformaciones eliminan observaciones iniciales hasta disponer de las ventanas necesarias.

2.5. Prevención de look-ahead

El procedimiento impone cuatro restricciones:

1. la respuesta siempre corresponde al retorno futuro;
2. el tuning usa únicamente train y validación;
3. la evaluación final no modifica hiperparámetros usando resultados del test; y
4. la calibración de un bloque utiliza solo errores observados en validación y en bloques de test ya realizados.

El checkpoint incluye un hash de datos, fechas, configuración, semillas y versión del paquete para impedir la mezcla accidental de resultados provenientes de especificaciones diferentes.

3. Modelos

3.1. Random Walk cuantílico

El benchmark denominado Random Walk supone que el retorno es impredecible condicionalmente y que la distribución relevante puede aproximarse con la distribución empírica reciente. Su pronóstico es:

$$\hat{q}_{\tau,t}^{RW} = Q_{\tau}\{y_s : s \in \mathcal{I}_t\}. \quad (3)$$

En sentido estricto, se trata de un benchmark de cuantiles históricos bajo retornos tipo caminata aleatoria, no de fijar el retorno pronosticado en cero. Es difícil de superar porque adapta automáticamente la escala a la volatilidad de la ventana, aunque no utiliza información condicional.

3.2. Regresión cuantílica lineal

Para cada τ , la regresión cuantílica estima:

$$\hat{\beta}_{\tau} = \arg \min_{\beta} \sum_{t \in \mathcal{I}_b} \rho_{\tau}(y_{t+1} - \mathbf{x}'_t \beta), \quad (4)$$

donde

$$\rho_{\tau}(u) = u [\tau - \mathbf{1}(u < 0)]. \quad (5)$$

La especificación utiliza los 46 predictores. Su ventaja es la transparencia; su limitación es que restringe los efectos marginales a ser lineales y aditivos. Como cada percentil se estima por separado, las predicciones se reordenan por observación para evitar cruces.

3.3. Quantile Random Forest

QRForest utiliza la estructura de Random Forest para estimar una distribución condicional ponderada. Si $w_i(\mathbf{x})$ es el peso inducido por la frecuencia con la que la observación i comparte nodos terminales con $\mathbf{x}$, entonces:

$$\hat{F}(y | \mathbf{x}) = \sum_{i=1}^n w_i(\mathbf{x}) \mathbf{1}(y_i \leq y), \quad (6)$$

y el cuantil se obtiene mediante:

$$\hat{q}_{\tau}^{QRF}(\mathbf{x}) = \inf\{y : \hat{F}(y | \mathbf{x}) \geq \tau\}. \quad (7)$$

La principal fortaleza es que un único bosque proporciona todos los percentiles y captura interacciones y no linealidades sin imponer una forma paramétrica [9]. El tuning emplea una pérdida normalizada por el Random Walk y pondera más las colas, evitando que la escala de la mediana domine la selección.

3.4. Bayesian Quantile Additive Regression Trees

3.4.1. Función cuantílica

QBART representa el cuantil condicional como suma de árboles:

$$q_\tau(\mathbf{x}) = G_\tau(\mathbf{x}) = \sum_{j=1}^m g(\mathbf{x}; T_{j,\tau}, M_{j,\tau}), \quad (8)$$

donde $T_{j,\tau}$ es la estructura del árbol y $M_{j,\tau}$ contiene los parámetros de sus nodos terminales. A diferencia de un BART de media, cada τ tiene su propio ensamble, por lo que variables y particiones pueden cambiar entre centro y colas.

La implementación de Kindo et al. utiliza una representación normal–exponencial de la distribución Laplace asimétrica [5]. Condicional en la variable latente ν_i :

$$y_i = G_\tau(\mathbf{x}_i) + \vartheta_{1,\tau}\nu_i + \sqrt{\phi\vartheta_{2,\tau}^2\nu_i} z_i, \quad z_i \sim N(0, 1), \quad (9)$$

con:

$$\vartheta_{1,\tau} = \frac{1 - 2\tau}{\tau(1 - \tau)}, \quad \vartheta_{2,\tau}^2 = \frac{2}{\tau(1 - \tau)}. \quad (10)$$

Esta mezcla permite actualizar árboles, nodos, latentes y escala mediante MCMC. Los priors estructurales siguen la lógica regularizadora de BART: la probabilidad de dividir un nodo a profundidad d es $\alpha(1 + d)^{-\beta}$, con $\alpha = 0.95$ y $\beta = 2$ [2].

3.4.2. Motor oficial y transformación de predictores

La corrida utiliza el kernel C++ oficial BayesQArt, fijado al commit `3f83a7f`. El motor local en R se conserva únicamente como implementación experimental y no participa en los resultados. Esta decisión se tomó porque el kernel local empleaba una secuencia de movimientos y ratios de aceptación simplificados que no garantizaban la misma posterior.

Antes de ingresar a QBART, cada predictor se transforma mediante su función de distribución empírica en la ventana de entrenamiento. Esta transformación monótona preserva el orden y hace que los cortes equidistantes del paquete se aproximen a cortes por cuantiles. Los valores de test se mapean usando exclusivamente la distribución del entrenamiento.

3.4.3. Reordenamiento de cuantiles

Como los tres ensambles se estiman por separado, pueden producir cruces. Se aplica reordenamiento por fila:

$$(\hat{q}_{0.05,t}, \hat{q}_{0.50,t}, \hat{q}_{0.95,t}) \leftarrow \text{sort}(\hat{q}_{0.05,t}, \hat{q}_{0.50,t}, \hat{q}_{0.95,t}), \quad (11)$$

siguiendo la idea de rearrangement monotónico de [1].

4. Tuning y especificación seleccionada

4.1. Tuning por percentil

La selección de QBARTse realiza separadamente para cada τ :

$$\hat{\theta}_\tau = \arg \min_{\theta \in \Theta} \sum_{t \in \mathcal{V}} \rho_\tau(y_{t+1} - \hat{q}_{\tau,t}(\theta)), \quad (12)$$

donde $\mathcal{V}$ es el bloque de validación. Esto corrige una limitación de la versión anterior, que promediaba las pérdidas de tres percentiles y daba peso implícitamente mayor a la mediana.

La grilla exploratoria considera:

$$\kappa \in \{0.5, 1, 2\}, \quad m \in \{50, 100\}, \quad n_{\min} \in \{5, 15\}, \quad d_{\max} = 3. \quad (13)$$

Cada configuración usa dos semillas, 200 iteraciones de burn-in y 300 iteraciones retenidas en tuning. La corrida fuera de muestra usa 1 000 de burn-in y 2 000 posteriores.

Cuadro 3: Hiperparámetros seleccionados por percentil

Percentil	κ	Árboles	$n_{\min}$	Profundidad	Pinball validación
5	0,5	50	5	3	0,04386
50	0,5	50	15	3	0,11580
95	2,0	50	15	3	0,03806

Los tres percentiles seleccionan 50 árboles. En esta grilla, aumentar a 100 árboles no mejora la validación. El percentil 5 prefiere nodos más pequeños y menor shrinkage, mientras que el percentil 95 selecciona mayor κ y nodos mínimos de 15 observaciones.

4.2. Tuning de QRF

QRFse ajusta de manera comparable con:

$$n_{\text{tree}} \in \{300, 500\}, \quad mtry \in \{6, 15\}, \quad n_{\min} \in \{5, 15\}. \quad (14)$$

El criterio es un promedio de pérdidas relativas al Random Walk con pesos (0.4, 0.2, 0.4) para los percentiles 5, 50 y 95. La especificación seleccionada utiliza 300 árboles, $mtry = 6$ y $n_{\min} = 15$. Sus pérdidas de validación son 0,03519, 0,10669 y 0,03179. Por tanto, la ventaja de QRFya era visible antes de observar el test: el mejor QBARTera 24,6 % peor en el percentil 5, 8,5 % peor en la mediana y 19,7 % peor en el percentil 95.

5. Calibración causal de QBART

5.1. Motivación

Tanto en simulaciones como en la aplicación real, el QBARTcrudo contrae los extremos hacia el centro: el percentil 5 queda demasiado alto y el percentil 95 demasiado bajo. Para separar error de localización de error de forma, se aplica una corrección aditiva basada en errores pasados.

Sea:

$$e_{\tau,s} = y_s - \hat{q}_{\tau,s}^{raw}. \quad (15)$$

Al inicio del bloque b , se calcula:

$$\hat{\delta}_{\tau,b} = Q_{\tau}(\{e_{\tau,s} : s < t_b\}_{\text{últimos 500}}), \quad (16)$$

y:

$$\hat{q}_{\tau,t}^{cal} = \hat{q}_{\tau,t}^{raw} + \hat{\delta}_{\tau,b}. \quad (17)$$

El historial inicial procede de predicciones de validación generadas con un modelo entrenado únicamente en train. Después se incorporan bloques de test ya observados. No se emplea información futura.




Figura 1: Evolución de los offsets de calibración.

La Figura 1 evidencia no estacionariedad. El ajuste del percentil 5 alcanza aproximadamente -0.61 y termina en -0.24 ; el del percentil 95 alcanza $+0.43$ y termina cerca de $+0.15$. La mediana requiere correcciones mucho menores. Esta evolución anticipa que una ventana de calibración fija puede ser demasiado lenta ante cambios de régimen.

6. Métricas y pruebas

6.1. Pérdida pinball

Para observaciones de test $\mathcal{T}$:

$$\hat{L}_\tau = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \rho_\tau(y_t - \hat{q}_{\tau,t}). \quad (18)$$

Es una regla de scoring propia para cuantiles. El ratio $\hat{L}_\tau^m / \hat{L}_\tau^{RW}$ menor que uno indica que el método m supera al Random Walk.

6.2. Cobertura

$$\hat{C}_\tau = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \mathbf{1}(y_t \leq \hat{q}_{\tau,t}). \quad (19)$$

Un cuantil está calibrado incondicionalmente si $\hat{C}_\tau \approx \tau$.

6.3. Kupiec, DQ y Diebold–Mariano

El test de Kupiec contrasta cobertura incondicional usando una razón de verosimilitudes binomial [7]. El test Dynamic Quantile (DQ) emplea:

$$H_t = \mathbf{1}(y_t \leq \hat{q}_{\tau,t}) - \tau \quad (20)$$

y prueba conjuntamente constante y cuatro rezagos mediante:

$$DQ = (\mathbf{X}'\mathbf{H})' [\tau(1 - \tau)\mathbf{X}'\mathbf{X}]^{-1} (\mathbf{X}'\mathbf{H}), \quad (21)$$

con distribución asintótica χ^2 bajo la nula [4]. Finalmente, Diebold–Mariano compara las pérdidas diarias de QBART y QRF usando una varianza HAC [3]. Una diferencia media positiva implica mayor pérdida de QBART.

7. Ejercicios de validación previos

7.1. Revisión del sampler

La primera implementación local actualizaba la variable latente una vez por iteración, simplificaba ratios Metropolis–Hastings y ejecutaba una sola propuesta estructural por árbol. Debido a que estas diferencias podían alterar la distribución objetivo, se substituyó por el kernel oficial. El motor local quedó bloqueado para resultados de investigación.

7.2. Simulation gate

Se generó una función no lineal heterocedástica con cuantiles verdaderos conocidos. La muestra completa del gate usa 400 observaciones de ajuste, 400 de calibración y 1 200 de test. QBART emplea 100 árboles, 1 000 iteraciones de burn-in y 1 500 posteriores.

Cuadro 4: Simulation gate completo

Percentil	Métrica	QBART crudo	QBART calibrado	QRF
5	Pinball	0,07654	0,06420	0,06058
	Cobertura	0,13583	0,04583	0,05500
50	Pinball	0,24402	0,24425	0,19810
	Cobertura	0,49917	0,51833	0,49917
95	Pinball	0,08568	0,06439	0,05883
	Cobertura	0,82500	0,95583	0,95833




Figura 2: Cobertura de los métodos en el simulation gate.

El ejercicio reproduce el sesgo hacia el centro incluso cuando la función generadora es conocida. Cadenas más largas mejoran estabilidad, pero no eliminan la contracción. La calibración corrige cobertura y deja a QBART entre 6,0 % y 9,4 % detrás de QRF en las colas. Esto anticipa que aumentar solamente el número de iteraciones no garantiza superar a QRF.

7.3. Pruebas de software

Se incorporaron pruebas de:

- disponibilidad obligatoria del motor oficial;
- hiperparámetros diferenciados por percentil;
- preservación del orden bajo rank transform;
- dimensiones, finitud y ausencia de cruces;
- calibración monotónica; y
- capacidad del test DQ para detectar cobertura incorrecta.

8. Resultados fuera de muestra

8.1. Pérdida pinball

Cuadro 5: Pérdida pinball fuera de muestra

Percentil	Random Walk	Reg. cuantílica	QRF	QBART crudo	QBART calibrado
5	0,05548	0,04853	0,04721	0,07255	0,05730
50	0,14642	0,14844	0,14634	0,17272	0,17317
95	0,04961	0,04551	0,04459	0,06416	0,05212

Menor es mejor. El valor en negrita identifica el mejor método por percentil.




Figura 3: Comparación de pérdida pinball.

QRF obtiene la menor pérdida en los tres percentiles. La calibración reduce la pérdida de QBART en 21,0 % para el percentil 5 y en 18,8 % para el 95, pero no mejora la mediana. Frente a QRF, las brechas del QBART calibrado son:

$$21.4 \% \quad (\tau = 0.05), \quad 18.3 \% \quad (\tau = 0.50), \quad 16.9 \% \quad (\tau = 0.95). \quad (22)$$

El QBART calibrado tampoco supera al Random Walk: sus ratios son 1,033, 1,183 y 1,051. La regresión cuantílica queda muy cerca de QRF en las colas, lo que sugiere que parte importante de la señal puede capturarse de forma lineal con el conjunto ampliado de predictores.

8.2. Cobertura

Cuadro 6: Cobertura empírica

τ	Nominal	Random Walk	Reg. cuantílica	QRF	QBART crudo	QBART calibrado
0,05	0,050	0,087	0,064	0,059	0,162	0,045
0,50	0,500	0,530	0,503	0,525	0,512	0,503
0,95	0,950	0,922	0,936	0,945	0,844	0,950




Figura 4: Cobertura observada y nominal.

La calibración alcanza una cobertura promedio más próxima a la nominal que QRF. Sin embargo, este resultado no contradice el ranking de pinball: una corrección aditiva puede ajustar la frecuencia promedio de violaciones sin mejorar suficientemente la localización condicional de cada pronóstico.

8.3. Backtests corregidos

Cuadro 7: Tests de cobertura y precisión

Método	τ	p Kupiec	p DQ	DM vs. QRF	p DM
QRF	0,05	0,127	0,052	–	–
	0,50	0,070	0,227	–	–
	0,95	0,416	0,149	–	–
QBART crudo	0,05	$< 10^{-50}$	$< 10^{-70}$	6,844	$< 10^{-11}$
	0,50	0,372	0,043	9,670	$< 10^{-21}$
	0,95	$< 10^{-47}$	$< 10^{-69}$	6,309	$< 10^{-9}$
QBART calibrado	0,05	0,424	0,001	4,918	$< 10^{-6}$
	0,50	0,850	0,071	9,617	$< 10^{-21}$
	0,95	0,936	$< 10^{-5}$	4,944	$< 10^{-6}$

QRFno es rechazado al 5 % por Kupiec ni por DQ. El percentil 5 tiene $p = 0.052$ en DQ y merece seguimiento, pero no cruza el umbral convencional. El QBARTcalibrado supera Kupiec en los tres casos y falla DQ en ambas colas. En consecuencia, la cobertura promedio correcta oculta clustering de violaciones y cambios de régimen.

Las estadísticas Diebold–Mariano son positivas y altamente significativas. La diferencia media diaria de pérdida de QBARTcalibrado respecto a QRFes 0,01009, 0,02682 y 0,00753 para los percentiles 5, 50 y 95. La hipótesis de igual precisión se rechaza a favor de QRF.

8.4. Comparación con la versión anterior

Cuadro 8: Cambio de desempeño respecto a la exploración anterior

Percentil	QBART anterior	QBART v2 calibrado	Cambio
5	0,06122	0,05730	−6,4 %
50	0,14651	0,17317	+18,2 %
95	0,05379	0,05212	−3,1 %

Las colas mejoran en términos absolutos respecto a la versión local anterior. No obstante, QRFtambién mejora aproximadamente 8,1 % y 8,3 % en las colas, por lo que la brecha relativa no se cierra. La comparación es indicativa: la incorporación de estadísticas móviles elimina once observaciones iniciales adicionales y modifica ligeramente la muestra.

9. Estabilidad temporal

9.1. Resultados anuales

Cuadro 9: Ratio anual de pérdida QBART calibrado/QRF

Año	Percentil 5	Mediana	Percentil 95
2021	1,241	1,138	1,233
2022	1,270	1,131	1,145
2023	1,240	1,171	1,208
2024	1,240	1,222	1,161
2025	1,198	1,319	1,227
2026	0,901	1,169	0,929




Figura 5: Evolución anual del desempeño relativo.

QBART pierde en ambas colas durante 2021–2025. En 2026 presenta ratios menores que uno: 0,901 y 0,929 para los percentiles 5 y 95. La evidencia es prometedora para el régimen reciente, pero se basa en 109 observaciones y no revierte el resultado completo. La mediana permanece detrás de QRF en todos los años.

9.2. Resultados por bloque




Figura 6: Diferencia de pérdida QBART menos QRF por bloque.

QBART gana solo 3 de 23 bloques en el percentil 5, 0 de 23 en la mediana y 3 de 23 en el percentil 95. Los mejores bloques de cola se concentran hacia el final de la muestra. La correlación entre la diferencia de pérdida y la volatilidad móvil de 20 días es cercana a 0,08 en ambas colas; por tanto, la desventaja no puede atribuirse únicamente a episodios de alta volatilidad.

10. Determinantes por percentil

10.1. Definición de la medida

El paquete oficial retorna la variable empleada cada vez que se acepta un nacimiento de rama durante MCMC. Para cada percentil se cuenta:

$$I_{j,\tau} = \frac{\#\{\text{nacimientos aceptados que usan } x_j\}}{\#\{\text{nacimientos aceptados}\}}. \quad (23)$$

Esta medida incluye burn-in, no registra negativamente las podas y no promedia el uso de variables sobre árboles posteriores almacenados. Por ello:

- no es una probabilidad posterior de inclusión;
- no mide efecto causal;
- puede estar influida por la frecuencia de propuestas aceptadas; y
- debe interpretarse como señal exploratoria de uso estructural.

La comparación entre percentiles es parcialmente favorecida porque los tres modelos seleccionan 50 árboles y usan la misma longitud de cadena.

10.2. Ranking principal

Cuadro 10: Principales señales de uso por percentil

Percentil 5		Mediana		Percentil 95	
Variable	Frec.	Variable	Frec.	Variable	Frec.
mean_abs_ret_20	0,066	d_oro	0,088	d_eur	0,070
vol_sd_20	0,062	d_mxn	0,076	d_gbp	0,062
skew_ret_20	0,062	kurt_ret_60	0,072	vol_ratio_5_60	0,062
ret_lag_4	0,058	ret_lag_1	0,060	d_cny	0,049
d_clp	0,054	interv_bcrp	0,054	d_rin	0,041
kurt_ret_60	0,054	d_vix	0,051	d_dxy	0,041
d_cobre	0,051	tp_5y	0,049	ret_lag_4	0,041
ret_lag_5	0,051	d_zinc	0,046	interv_bcrp	0,037




Figura 7: Ocho señales principales en cada percentil.




Figura 8: Mapa de frecuencias absolutas para la unión de variables principales.

10.3. Interpretación de la cola izquierda

La cola izquierda está dominada por medidas de variabilidad y forma: media absoluta de retornos, volatilidad de 20 días, asimetría de 20 días y curtosis de 60 días. También aparecen rezagos 4 y 5. El patrón sugiere que los movimientos extremos negativos dependen de persistencia y acumulación de volatilidad, más que de una única noticia contemporánea.

Entre las variables externas destacan CLP, cobre, plata, WTI y CHF. El peso de CLP y cobre es coherente con exposición regional y de commodities. La intervención del BCRP también aparece entre las diez primeras variables, pero su frecuencia no debe interpretarse causalmente: la intervención es endógena a presiones cambiarias y puede funcionar como indicador de estrés y

como respuesta amortiguadora simultáneamente.

10.4. Interpretación del centro

La mediana asigna mayor frecuencia a oro, MXN, curtosis de 60 días, retorno reciente, intervención del BCRP, variación del VIX y term premium a cinco años. Este conjunto es más heterogéneo y combina factores globales, regionales y persistencia del retorno.

La importancia central no debe utilizarse como denominador mecánico cuando es cercana a cero. Ratios cola/centro muy grandes, por ejemplo para DXY o S&P 500, pueden reflejar un denominador diminuto. Es preferible comparar diferencias absolutas y estabilidad entre semillas.

10.5. Interpretación de la cola derecha

La cola derecha presenta mayor frecuencia en EUR, GBP, CNY, DXY, reservas y el ratio de volatilidad 5/60. Bajo la convención soles por dólar, esta es la cola asociada a depreciaciones extremas del sol. El patrón combina:

1. un componente de dólar y monedas internacionales;
2. capacidad de intervención, aproximada por reservas;
3. aceleración de volatilidad de corto plazo; y
4. persistencia del retorno mediante rezagos.

La intervención aparece nuevamente entre las variables principales. El VIX en nivel tiene una frecuencia relativamente mayor en las colas que en el centro, mientras que su variación diaria aparece más en la mediana. Esto podría indicar que el régimen de riesgo global importa más que una variación aislada para los eventos extremos.

10.6. Asimetrías relevantes

La comparación sugiere asimetrías económicamente plausibles:

- la cola izquierda enfatiza acumulación de volatilidad, asimetría, commodities y monedas regionales;
- la cola derecha enfatiza monedas globales, DXY, reservas y aceleración de volatilidad;
- intervención y dinámica rezagada aparecen en centro y colas; y
- las variables de volatilidad son importantes en ambas colas, pero con horizontes distintos: 20 días en la izquierda y 5/60 en la derecha.

Estas diferencias responden a la pregunta de investigación en sentido exploratorio: los árboles construyen particiones diferentes por percentil. No obstante, una afirmación definitiva requiere una medida posterior de inclusión o importancia por permutación con incertidumbre.

11. Ejercicios adicionales de análisis

11.1. Ensamble diagnóstico QBART–QRF

Se calculó, solo como diagnóstico ex post, el peso w que minimiza la pérdida de:

$$\hat{q}_\tau^{ens} = w\hat{q}_\tau^{QRF} + (1 - w)\hat{q}_\tau^{QBART}. \quad (24)$$

Cuadro 11: Ensamble diagnóstico ex post

Percentil	Peso óptimo de QRF	Mejora sobre QRF
5	0,92	0,334 %
50	1,00	0,000 %
95	0,95	0,037 %

Incluso con pesos elegidos mirando el test, el ensamble asigna casi toda la masa a QRFy genera mejoras económicamente despreciables. Por ello, un promedio simple no resolvería la brecha actual.

11.2. Concentración de señales

Las diez variables principales concentran 54,5 % de los nacimientos aceptados en el percentil 5, 57,3 % en la mediana y 47,7 % en el percentil 95. La cola derecha está algo menos concentrada, consistente con un conjunto más diverso de canales internacionales.

11.3. Evaluación de régimen

La ventaja reciente de QBARTno se explica linealmente por la volatilidad de 20 días: la correlación entre diferencia de pérdida y volatilidad es aproximadamente 0,07–0,08. Esto sugiere que la fuente de heterogeneidad puede involucrar composición de choques, relaciones no lineales o la adaptación de los offsets, no solo la magnitud de la volatilidad.

12. Limitaciones

1. **Exploración MCMC.** Se utilizan 1 000 iteraciones de burn-in y 2 000 posteriores. Son más que un smoke test, pero menos que la configuración completa de 3 000 y 5 000.
2. **Ausencia de draws en la interfaz oficial.** El paquete devuelve medias posteriores de predicción, no draws guardados. No pueden calcularse ESS, $\hat{R}$, intervalos posteriores ni estabilidad de funciones cuantílicas sin modificar C++.
3. **Importancia imperfecta.** La frecuencia de nacimientos aceptados incluye burn-in y no equivale a inclusión posterior.

4. **Distribución Laplace asimétrica.** La mezcla ALD facilita MCMC, pero puede inducir una forma de error demasiado restrictiva. La fuerte contracción de colas aparece también en simulación.
5. **Reestimación en bloques.** Los modelos no se actualizan dentro de cada bloque de 60 observaciones.
6. **Calibración aditiva.** El offset corrige localización promedio, pero no utiliza covariables ni modela explícitamente cambios en dispersión.
7. **Timing de publicación.** Las transformaciones son causales en índice temporal, pero una versión final debe documentar lags de publicación y horarios de cierre de cada serie.
8. **Intervención endógena.** Su frecuencia en árboles no identifica un efecto causal del BCRP.
9. **Un solo horizonte.** Los resultados corresponden a un día y no necesariamente se extienden a horizontes semanales o mensuales.

13. Agenda para mejorar QBART

13.1. Prioridad 1: calibración dinámica

Antes de una corrida completa se recomienda:

1. reconstruir las predicciones de validación y guardarlas;
2. comparar ventanas de calibración de 125, 250 y 500 observaciones;
3. estimar offsets separados por régimen de volatilidad;
4. evaluar Adaptive Conformal Inference para actualizar cobertura objetivo; y
5. seleccionar la regla exclusivamente con un backtest prequential de validación.

Este ejercicio requiere reestimar solo tres modelos de validación y después reutiliza las predicciones crudas. Su costo estimado es 15–25 minutos, muy inferior a repetir la evaluación completa.

13.2. Prioridad 2: mejorar la distribución de error

La corrección necesaria de aproximadamente -0.41 en la cola izquierda y $+0.29$ en la derecha indica un problema estructural de escala. Conviene comparar:

- una Laplace asimétrica generalizada;
- mezclas con colas tipo Student- t ;
- BART distribucional con escala dependiente de $\mathbf{x}$; y
- un modelo conjunto de varios cuantiles con restricción de no cruce.

13.3. Prioridad 3: sparsity y selección de variables

Con 46 predictores, el prior uniforme de variables puede diluir señal. Una extensión DART o Dirichlet sobre probabilidades de split permitiría concentrar masa en variables relevantes. Como alternativa, se puede realizar preselección anidada por percentil usando únicamente train y validación.

13.4. Prioridad 4: inferencia posterior e importancia robusta

Debe modificarse el kernel C++ para guardar:

- predicciones por draw;
- ϕ , tamaño y profundidad de árboles;
- tasas de aceptación por movimiento;
- conteos de variables por draw posterior, excluyendo burn-in; y
- estado de los árboles para warm starts.

Con ello podrían calcularse intervalos, ESS, $\hat{R}$, probabilidades de inclusión y estabilidad entre cadenas. Para determinantes, también se recomienda importancia por permutación medida directamente en incremento de pinball, repetida por percentil y bloque temporal.

13.5. Prioridad 5: ventanas y regímenes

La señal favorable en 2026 justifica comparar ventanas de 1 000, 1 500 y 2 520 observaciones y ponderación exponencial. La selección debe realizarse en backtests de validación, no mirando el test. También conviene reportar resultados en submuestras de estrés, intervención intensa y alta volatilidad.

13.6. Prioridad 6: eficiencia computacional

La corrida exploratoria utilizó aproximadamente un núcleo lógico y tardó seis horas. La versión completa no debe lanzarse secuencialmente. Se propone:

1. paralelizar configuraciones y semillas de tuning en 6–8 workers;
2. paralelizar los tres percentiles dentro de cada bloque;
3. mantener los bloques secuenciales para respetar la información;
4. guardar checkpoints también durante tuning; y
5. registrar tiempos, memoria, semillas y commit en cada ajuste.

La evaluación por bloque podría acelerarse aproximadamente tres veces, porque contiene tres ajustes QBART independientes.

13.7. Criterio para autorizar la corrida completa

La corrida completa solo debería ejecutarse si una nueva especificación cumple simultáneamente en validación:

1. cobertura dentro de ± 0.02 en ambos extremos;
2. no rechazo de DQ al 5 %;
3. pinball no mayor a 1,05 veces el de QRF en cada cola;
4. estabilidad en al menos dos semillas; y
5. mejora en más de la mitad de los bloques de validación.

14. Conclusiones

El experimento permite separar dos dimensiones. En calibración incondicional, la versión v2 de QBART funciona: corrige la cobertura de colas hasta valores muy próximos a 0,05 y 0,95. En precisión condicional, QRF superior: tiene menor pinball en los tres percentiles, supera los backtests dinámicos y gana la mayoría de los bloques. La diferencia es estadísticamente significativa y un ensamble ex post asigna entre 92 % y 100 % del peso a QRF.

La principal lección metodológica es que cobertura promedio no basta. Los offsets corrigen el nivel de los cuantiles, pero no su dinámica. El rechazo de DQ en las colas y las variaciones anuales muestran que QBART necesita una calibración más adaptativa o una distribución de error más flexible.

La exploración de determinantes sí revela perfiles diferenciados. La cola izquierda concentra medidas de volatilidad persistente, asimetría y commodities; la derecha enfatiza monedas globales, DXY, reservas y aceleración de volatilidad. La intervención del BCRP aparece de manera recurrente. Estos resultados son hipótesis económicas valiosas, pero aún no constituyen inferencia posterior ni causal.

En consecuencia, no se recomienda aumentar mecánicamente árboles y draws. La siguiente etapa debe mejorar calibración dinámica, flexibilidad de escala, sparsity e inferencia de importancia. Solo después de superar un nuevo gate de validación tiene sentido asumir el costo de la corrida completa.

A. Reproducibilidad

A.1. Archivos principales

Archivo	Contenido
QBART_riesgo_de_cola.R	Pipeline completo de datos, tuning, evaluación, calibración y resultados.

Archivo	Contenido
notebooks/qbart_adapter.R	Interfaz segura al kernel oficial y transformación de predictores.
src/qbart_features.R	Construcción causal de respuesta y 46 predictores.
src/qbart_workflow.R	Pinball, cobertura, tuning, calibración, Kupiec, DQ y DM.
tests/qbart_simulation_gate.R	Simulación heterocedástica con cuantiles conocidos.
tests/test_qbart_components.R	Pruebas de interfaz, monotonidad y backtests.
scripts/ build_qbart_report_assets.R	Generación reproducible de figuras y tablas del presente informe.

A.2. Comandos

```
Rscript --vanilla scripts/install_qbart_deps.R
Rscript --vanilla tests/test_qbart_components.R
Rscript --vanilla tests/qbart_simulation_gate.R
```

```
$env:QBART_MODE="exploracion"
$env:QBART_WINDOW_OBS="2520"
$env:QBART_REESTIMATION_STEP="60"
Rscript --vanilla QBART_riesgo_de_cola.R
```

```
Rscript --vanilla scripts/build_qbart_report_assets.R
```

B. Lista completa de predictores

Grupo	Variables
Niveles	vix, baa10y, tasa_usa, nfci, yield_to_worst, tp_1y, tp_5y, tp_10y, embig_peru.
Política y tasas	d_vix, diff_tasas, interv_bcrp, interv_bcrp_missing.
Precios y monedas	d_rin, d_oro, d_cobre, d_zinc, d_plata, d_spx, d_mxef, d_dxy, d_jpy, d_chf, d_eur, d_gbp, d_clp, d_cop, d_mxn, d_brl, d_cny, d_wti.
Rezagos	ret_lag_1, ret_lag_2, ret_lag_3, ret_lag_4, ret_lag_5, abs_ret_lag_1, sq_ret_lag_1.
Volatilidad y forma	vol_sd_5, vol_sd_20, vol_sd_60, vol_ewma_094, mean_abs_ret_20, skew_ret_20, kurt_ret_60, vol_ratio_5_60.

Referencias

- [1] Chernozhukov, V., Fernández-Val, I. y Galichon, A. (2010). Quantile and probability curves without crossing. *Econometrica*, 78(3), 1093–1125.
- [2] Chipman, H., George, E. y McCulloch, R. (2010). BART: Bayesian additive regression trees. *The Annals of Applied Statistics*, 4(1), 266–298.
- [3] Diebold, F. y Mariano, R. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- [4] Engle, R. y Manganelli, S. (2004). CAViaR: Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- [5] Kindo, B., Wang, H., Hanson, T. y Peña, E. (2016). Bayesian quantile additive regression trees. *arXiv preprint arXiv:1607.02676*.
- [6] Koenker, R. y Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- [7] Kupiec, P. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73–84.
- [8] Meese, R. y Rogoff, K. (1983). Empirical exchange rate models of the seventies: Do they fit out of sample? *Journal of International Economics*, 14(1–2), 3–24.
- [9] Meinshausen, N. (2006). Quantile regression forests. *Journal of Machine Learning Research*, 7, 983–999.